

Profesor: Héctor Bahamonde, PhD.

e: hector.bahamonde@uoh.cl

w: www.hectorbahamonde.com

Curso: MLE.

TA: Gonzalo Barria.

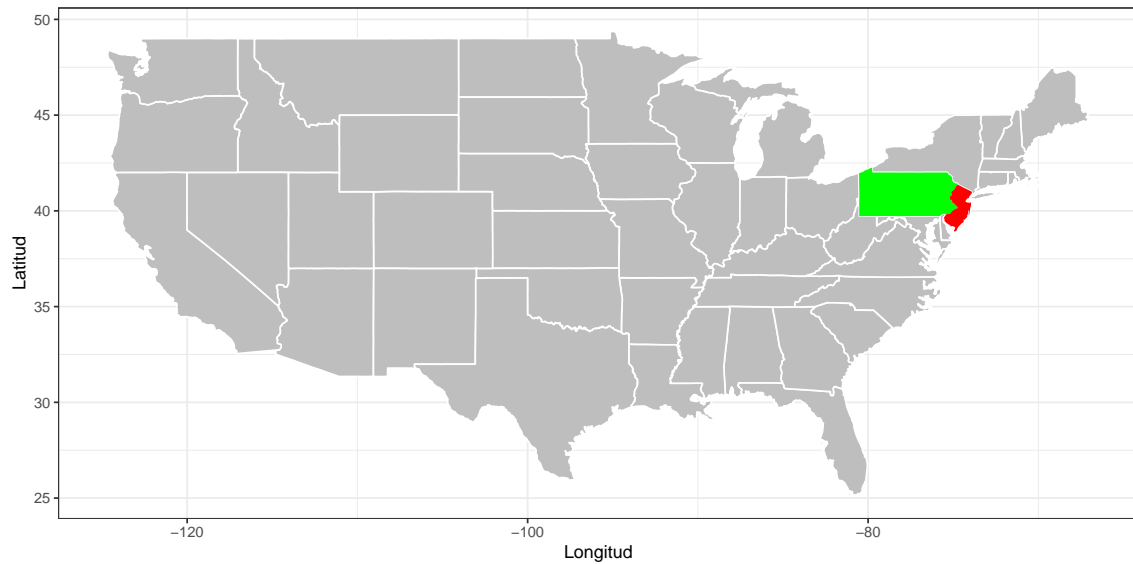
I. DIF IN DIF

Card and Krueger (1994) tratan de usar la geografía como *as-if random factor* (?). La pregunta que ellos tenían era cuál es el efecto (causal?) en el empleo ante un incremento en el salario en el sector de comida rápida. En otras palabras, *qué ocurre con el empleo en este sector cuando aumenta el salario, sube o baja?*

```
# instalar librerías
p_load(ggplot2, dplyr, maps)

# declarar datos
all_states <- map_data("state")

# plot
ggplot(all_states,
       aes(x=long, y=lat, group = group)) +
  geom_polygon(fill="grey", colour = "white") +
  geom_polygon(fill="green", data = filter(all_states, region %in% c("pennsylvania"))) +
  geom_polygon(fill="red", data = filter(all_states, region %in% c("new jersey")))
  ) +
  theme_bw() +
  xlab("Longitud") +
  ylab("Latitud")
```




Sin embargo, PA y NJ puede que hayan sido distintos en varias características (que es lo más probable, no?). El problema es que si quisiéramos calcular el efecto causal $\text{Desempleo}_{PA} - \text{Desempleo}_{NJ}$ cuando subimos el salario en NJ, ya PA podría contar con un piso que no estemos tomando en consideración. Cómo podríamos calcular el efecto causal τ , pero *tomando en cuenta las características de base de PA*?

Veámos un gráfico que podría aclarar lo que queremos.

```
plot(c(0, 1), c(6, 8),
     type = "p",
     ylim = c(5, 12),
     xlim = c(-0.3, 1.3),
     main = "El Estimador de Difference in Difference",
     xlab = "Periodo",
     ylab = "Desempleo",
     col = "steelblue",
     pch = 20,
     xaxt = "n",
     yaxt = "n")
#
```

```
axis(1, at = c(0, 1), labels = c("Antes", "Despues"))
axis(2, at = c(0, 13))
# treatment
points(c(0, 1, 1), c(7, 9, 11),
       col = "darkred",
       pch = 20)
#
lines(c(0, 1), c(7, 11), col = "darkred")
lines(c(0, 1), c(6, 8), col = "steelblue")
lines(c(0, 1), c(7, 9), col = "darkred", lty = 2)
lines(c(1, 1), c(9, 11), col = "black", lty = 2, lwd = 2)
#
text(1, 10, expression(tau), cex = 0.8, pos = 4)
text(0, 5.5, "Control antes (PA)", cex = 0.8, pos = 4)
text(0, 6.8, "Treated antes (NJ)", cex = 0.8, pos = 4)
text(1, 7.9, "Control despues (PA)", cex = 0.8, pos = 4)
text(1, 11.1, "Treated despues (NJ)", cex = 0.8, pos = 4)
```

El Estimador de Difference in Difference



- Cuál es el contrafactual?
- Qué significa o cómo leemos τ ?

De manera más formal, $\tau = \beta_1$ en [Equation 1](#):

$$\Delta y_i = \beta_0 + \beta_1 z_i + \epsilon_i \quad (1)$$

donde z es el *estado* del tratamiento, básicamente un vector x de 0's y 1's, Δy_i es la diferencia (el “delta”) en y cuando $z(0)$ cambia a $z(1)$, y $\tau = \beta_1$ es el *DID estimator* especificado en [Equation 2](#):


$$\tau = (y_{\text{Control Antes}} - y_{\text{Control Después}}) - (y_{\text{Treated Antes}} - y_{\text{Treated Después}}) \quad (2)$$

Si te fijas, el estimador es “la diferencia de la diferencia” (o “*difference in difference*”).

Cocinemos unos datos.

```
n <- 200
# definir tau
TEffect <- 4
# generar dummy de treatment
z <- c(rep(0, n/2), rep(1, n/2))
# simular pre y post treatment en la y
y_pre <- 7 + rnorm(n)
y_pre[1:n/2] <- y_pre[1:n/2] - 1
y_post <- 7 + 2 + TEffect * z + rnorm(n)
y_post[1:n/2] <- y_post[1:n/2] - 1
#
p_load(scales) # para usar alpha abajo (colores)
pre <- rep(0, length(y_pre[z==0]))
post <- rep(1, length(y_pre[z==0]))
# t=1
plot(jitter(pre, 0.6),
     y_pre[z == 0],
```

```
ylim = c(0, 16),
col = alpha("steelblue", 0.3),
pch = 20,
xlim = c(-0.5, 1.5),
ylab = "Y",
xlab = "Periodo",
xaxt = "n",
main = "Simulacion del DID Estimator")
axis(1, at = c(0, 1), labels = c("Antes", "Despues"))
# treatment t=1
points(jitter(pre, 0.6),
       y_pre[z == 1],
       col = alpha("darkred", 0.3),
       pch = 20)
# control t=2
points(jitter(post, 0.6),
       y_post[z == 0],
       col = alpha("steelblue", 0.5),
       pch = 20)
# treatment t=2
points(jitter(post, 0.6),
       y_post[z == 1],
       col = alpha("darkred", 0.5),
       pch = 20)
# lineas
lines(c(0, 1), c(mean(y_pre[z == 1]), mean(y_post[z == 1])), col = "darkred")
lines(c(0, 1), c(mean(y_pre[z == 0]), mean(y_post[z == 0])), col = "steelblue")
lines(c(0, 1), c(mean(y_pre[z == 1]), mean(y_post[z == 0]) +
(mean(y_pre[z == 1]) - mean(y_pre[z == 0]))), col = "darkred", lty = 2)
```



Ahora calculemos τ a mano:

```
mean(y_post[z == 1]) - mean(y_pre[z == 1]) -
(mean(y_post[z == 0]) - mean(y_pre[z == 0]))

## [1] 4.371355
```

Tambien podemos usar [Equation 1](#) para calcular τ (que recuerda es igual a β_1):

```
lm(I(y_post - y_pre) ~ z)

##
## Call:
## lm(formula = I(y_post - y_pre) ~ z)
##
## Coefficients:
## (Intercept)          z
##      1.752      4.371
```

Nota que z es el *estado* del tratamiento, basicamente un vector x de 0's y 1's, y τ es el *efecto* “causal” asociado a la administración de z . Es análogo a decir $\beta_1 x_1$.

```
knitr::purl('FE_DifDif.Rnw')

## Error in parse_block(g[-1], g[1], params.src, markdown_mode): Duplicate chunk label
## 'setup', which has been used for the chunk:
## if (!require("pacman")) install.packages("pacman"); library(pacman)
## p_load(knitr)
## set.seed(2020)
## options(scipen=9999999)
## if (!require("pacman")) install.packages("pacman"); library(pacman)

Stangle('FE_DifDif.Rnw')

## Writing to file FE_DifDif.R
```

REFERENCES

Card, David and Alan Krueger (1994). “Minimum Wages and Employment: A Case Study of the Fast-Food Industry in New Jersey and Pennsylvania.” In: *The American Economic Review* 84.4, pp. 772–793.