

**Profesor:** Héctor Bahamonde, PhD.

**e:** [hector.bahamonde@uoh.cl](mailto:hector.bahamonde@uoh.cl)

**w:** [www.hectorbahamonde.com](http://www.hectorbahamonde.com)

**Curso:** MLE.

**TA:** Gonzalo Barria.

## PROBABILIDAD Y LIKELIHOOD

Usualmente, nosotros estimamos la relación entre  $x$  e  $y$  vía un modelo lineal OLS ([Equation 1](#)).

$$y_i = \alpha + \beta_1 x_1 + \epsilon_i \quad (1)$$

En este setup, siempre hablamos de “probabilidad”. Es claro que [Equation 1](#) nos muestra que los valores de  $y_i$  dependen de  $\mathbf{x}$  (que es una matrix que contiene  $\alpha$  y todos los  $x$ 's), más el residuo  $\epsilon$ . Cada parámetro tiene un statement de probabilidad (recuerden el *p-value*).

Es decir, la probabilidad de  $y$  depende de  $\mathbf{x}$ , lo que significa que en este paradigma, **y depende de un modelo** ( $M$ ). Recuerda que cada vez que pones una  $x$  a la mano derecha de la igualdad, estás haciendo un modelo (estás especificando que la realidad depende de ciertas variables independientes). Más formalmente, esta noción se demuestra en [Equation 2](#):

$$Pr(y|M) = Pr(\text{datos}|\text{modelo}) \quad (2)$$

donde en [Equation 2](#)  $M$  es asumido “fijo” o “conocido” (“fixed”) y los datos “random”. *Lo son?* Recuerda que incluso existe la noción del *true model* (un modelo verdadero que existe “por ahí”, pero que es inaccesible para nosotros). King (1998, p. 16) explica que cuando “ $M$  is treated as given is a problem because uncertainty in inference lies with the model, not the data.”

- **$M$ : no puede ser tratado como conocido.** Los modelos se construyen. Nadie viene a darnos el modelo correcto.
- **datos:** no pueden ser *random*. La naturaleza ya ha producido los datos. Es más, y por esta misma razón, los datos debieran ser considerados como “datos” o “conocidos”. No?

Qué diferencias existen entre los conceptos de *probabilidad* y *likelihood*?

### Probabilidad: Incertidumbre Absoluta

Las probabilidades, todas, “viven” entre el 0 y 1.

$$\begin{aligned} Y &\sim f(y|\theta, \alpha) \\ \theta &= g(\mathbf{X}, \beta) \end{aligned} \quad (3)$$

donde la primera línea se lee “ $y$  se distribuye como una función de  $y$  que depende de  $\theta$  (que es  $\hat{y}$ , o el valor esperado de  $y_i$ , y  $\alpha$ ”. El valor  $\alpha$  se puede entender como parametro que está presente sólo en algunos modelos GLMs, o está dado por otros factores. Por ejemplo,  $\sigma^2$  (la varianza) está dada, no se estima (pero se asume que es **constante**). La segunda línea es una implicación de la primera, y se lee así: “donde  $\theta$  es igual a una función  $g$ , donde metemos los datos observados  $\mathbf{X}$  y calculamos los parametros  $\beta$ ”.

Lo unico que estamos haciendo, es hacer la transición a la notación de MLE. En este caso, estamos viendo dónde “viven” los parámetros y los datos observados y predichos, pero en lenguaje MLE. Si te fijas,  $\theta$  (la caja que contiene  $\mathbf{X}$  y  $\beta$ ) es tomado como “true parameter”. Si el modelo es tomado como “verdadero”, qué implicancias tiene el estimado  $\beta$ ? Piensa en los intervalos de confianza.

### *Likelihood: Incertidumbre Relativa*

En lenguaje de likelihood (que se expresa con el carácter griego  $\theta$ ) se refiere a un parámetro  $\theta_i$  de los infinitos parámetros  $\theta$  entre todos los modelos posibles ( $\tilde{\theta}$ ). Recuerda, en Equation 3  $\beta$  se refiere a los “true values”. Eso quiere decir que OLS y MLE tienen llegadas distintas: en MLE existen tantos  $\theta$  como hay datos. Esto implica que la incertidumbre en MLE está anclada a los datos (no al modelo). En otras palabras, en likelihood la incertidumbre es *relativa* porque el likelihood  $\theta$  no depende del modelo ( $\tilde{\theta}$ ) sino que de los datos. Es por esto que en likelihood uno piensa en términos de qué modelo ( $\tilde{\theta}$ ) **maximiza** el likelihood de haber creado los datos  $y$ . **A diferencia del lenguaje de probabilidad, los datos no son tomados como “datos”.**

$$\begin{aligned} L(\tilde{\theta}|y) &= k(y)Pr(y|\tilde{\theta}) \\ &\propto Pr(y|\tilde{\theta}) \end{aligned} \tag{4}$$

donde  $k(y)$  es una función constante positiva desconocida que depende de  $y$  (y cambia cada vez que  $y$  cambia). Si te fijas, en probabilidad (Equation 2) la probabilidad es  $Pr(y|M)$ , pero en likelihood (Equation 4) la probabilidad de  $Pr(y|\tilde{\theta})$  es “proporcional” (i.e.  $\propto$ ) a  $L(\tilde{\theta}|y)$ . Fíjate cómo se invierten los términos.

Esto implica que los likelihoods de dos modelos pueden ser comparados, pero sólo si bienen de los mismos datos (recuerda que  $k(y)$  depende de  $y$ ). Al contrario, en probabilidad, la probabilidad de que algo pase, *siempre* va entre 0 y 1 (independiente de los datos o los modelos usados). En cambio, los likelihoods pueden tomar cualquier número y no son necesariamente comparables (son como los errores estándar en un modelo lineal—sólo toman significancia dentro de ese modelo en particular).

## REFERENCES

King, Gary (1998). *Unifying Political Methodology: The Likelihood Theory of Statistical Inference*. Ann Arbor, MI: University of Michigan Press, pp. 1–274.