

Profesor: Héctor Bahamonde, PhD.

e: hector.bahamonde@uoh.cl

w: www.hectorbahamonde.com

Curso: MLE.

TA: Gonzalo Barria.

I. PROPIEDADES DE LOS ESTIMADORES MLE

1. Invariance to reparameterization: estimaciones se pueden transformar y no alteran su valor substantivo. Por ej., tomar un log o elevar al cuadrado.
2. Invariance to sampling plans: debido a que los estimadores dependen de los datos usados (son particulares a ellos, y no son generales), Es por esto que variando el tamaño de la muestra no varía la calidad de los estimadores.
3. $\hat{\theta}$ no está sesgado. Es decir, en la medida que se repitan los experimentos, $\hat{\theta}$ no cambia.
4. $\hat{\theta}$ es consistente. Dentro de todo el “parameter space”, existe un “spike” (una punta) que representa el verdadero parametro θ .
5. El “parameter space” de $\hat{\theta}$ esta normalmente distribuido.

II. PRECISIÓN DE LOS ESTIMADORES MLE

Pensar en la precisión, es pensar en cuán bien (o mal) nuestro estimador $\hat{\theta}$ (i.e. “nuestro β ”) maximice el likelihood the que $E(y) = \pi$. Para esto, debemos recordar que la función del LL es relativa (depende de los datos). No es como antes en OLS, donde podíamos comparar p -values, r^2 y otros *entre modelos con distintos datasets*. Aquí no.

En este curso veremos dos tipos de tests, el LLR y el Wald Test. Ambos usan la distribución del log-likelihood para estimar lo mismo, pero “por lados diferentes”. Ve la figura 2.1 de Ward and Ahlquist (2018, p. 37).




FIGURE 2.1 Geometrical interpretation of the likelihood ratio (LR), Lagrange multiplier/score (LM), and the Wald (W) test statistics.

Likelihood Ratio Test (LLR)

$$\begin{aligned}\mathfrak{R} &= 2\ln\left(\frac{L_{R_*}}{L_*}\right) \\ &= 2(\ln L_* - L_{R_*})\end{aligned}\tag{1}$$

donde L_* es el likelihood del modelo “entero” y L_{R_*} es el likelihood del modelo “restringido”. “Entero” significa que tiene todos los efectos estimados, mientras que el “restringido” tiene los efectos *restringidos* a 0.

Volvamos a usar el lenguaje OLS para ver qué significa “entero” y “restringido”. Supongamos que tenemos dos modelos compitiendo; **ambos se construyeron usando la misma base de datos** (entonces, los podemos comparar).

$$y_i = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \epsilon_i \quad (2)$$

$$\begin{aligned} y_i &= \beta_0 + 0x_1 + \beta_2 x_2 + \epsilon_i \\ y_i &= \beta_0 + 0 + \beta_2 x_2 + \epsilon_i \end{aligned} \quad (3)$$

Aquí lo que hemos hecho es que el modelo en Equation 2 está “entero”. Sin embargo, el modelo en la Equation 3 está “restringido”; hemos “restringido” el valor de $\beta_1 = 0$. Nota que $0 \times x_1 = 0$. La entonces pregunta que nos ayuda a resolver el LLR es *qué modelo es mejor? El restringido o el entero?* Comparemos sus respectivos LLRs.

Si $L_\star = L_{R_\star}$ entonces $\mathfrak{R} = 1$. Pero si el likelihood del modelo “entero” L_\star es mejor, entonces $\mathfrak{R} \geq 1$. Por ejemplo, si $L_\star = -72.86$ y $L_{R_\star} = -81.27$, entonces,

$$\begin{aligned} \mathfrak{R} &= 2\ln\left(\frac{L_{R_\star}}{L_\star}\right) \\ &= 2(\ln -72.86 - -81.27) \\ &= 16.8 \end{aligned} \quad (4)$$

Aquí podemos concluir que el modelo “entero” es mejor, y que debemos quedarnos con este.

Wald Test El LRT funciona cuando mejor cuando tenemos un número limitado de hipótesis. En el ejemplo anterior contrastamos la hipótesis donde Equation 2 era mejor que Equation 3 (y concluimos que Equation 2 era mejor). *Qué pasa cuando tienes muchas hipótesis y resulta complicado restringir varios parametros a cero?* Para eso usamos el *Wald test*. La ventaja de este test es que “only the unrestricted model need be estimated; from that model, one can perform tests against any number of alternatives” (King 1998, p. 87).

El Wald test es un tipo de t-test. De nuestro conocimiento de OLS sabemos que una vez obtenido el t-test, es posible calcular el p-value.

Recordemos primero el t-test:

$$t = \frac{\hat{\mu}_s - \tilde{\mu}_p}{\frac{\hat{\sigma}}{\sqrt{n}}} \quad (5)$$

donde $\hat{\mu}_s$ es el *sample mean* (lo que observamos), $\tilde{\mu}_p$ es el *population mean* (lo que no observamos), y $\hat{\sigma}$ es la desviación estándar estimada. Ahora veamos el Wald test,

$$\mathbb{W} = \frac{\hat{\beta} - \tilde{\beta}}{\hat{\sigma}} \quad (6)$$

donde, de manera análoga al t-test en Equation 5, $\hat{\beta}$ es el valor promedio estimado (lo que observamos), y a diferencia del t-test, $\tilde{\beta}$ es un posible valor de β , mientras que $\hat{\sigma}$ es el error estándar de $\hat{\beta}$.

Veamos el siguiente ejemplo, donde de nuevo trataremos de testear la diferencia entre nuestro modelo “entero” (Equation 2) y nuestro modelo “restringido” (Equation 3). Supongamos que nuestro modelo OLS en la Equation 2 $\hat{\beta}_1 = -2.30$ (con error estándar estimado de $\hat{\sigma} = 0.5$), y que nosotros queremos testear si $\hat{\beta}_1 = 0$, o más precisamente, que uno de los posibles valores de $\hat{\beta}_1$ es $\tilde{\beta}_1 = 0$. Para eso, restringimos nuestro modelo (como en Equation 3).

$$\begin{aligned} \mathbb{W} &= \frac{\hat{\beta}_1 - \tilde{\beta}_1}{\hat{\sigma}} \\ \mathbb{W} &= \frac{-2.30 - 0}{0.5} \\ \mathbb{W} &= -4.60 \end{aligned} \quad (7)$$

Dado que $\mathbb{W} = -4.60$, podemos sugerir que el modelo restringido (Equation 3) está -4.60 **desviaciones estándar lejos** del modelo entero (Equation 2)—es decir, ambos son substancialmente diferentes. Si realmente $\hat{\beta}_1 = 0$, entonces $\tilde{\beta}_1 = 0$, lo que hubiera implicado que $\mathbb{W} = 0$, pero en este caso es -4.60 . Esto significa que debemos rechazar la idea de que $\hat{\beta}_1 = 0$ (rechazando así el modelo restringido, Equation 3), y quedándose con el modelo entero (Equation 2) donde $\hat{\beta}_1 = -2.30$.

- La ventaja del Wald test es que podemos testear si múltiples parámetros son iguales a cero (u

otro valor).

- Debiera ser claro en este momento que ultimamente, lo que busca este test, es sugerir si un parámetro aporta al modelo (mejorando su likelihood) o no.

REFERENCES

- King, Gary (1998). *Unifying Political Methodology: The Likelihood Theory of Statistical Inference*. Ann Arbor, MI: University of Michigan Press, pp. 1–274.
- Ward, Michael and John Ahlquist (2018). *Maximum Likelihood for Social Science: Strategies for Analysis*.