

**Profesor:** Héctor Bahamonde, PhD.

**e:** [hector.bahamonde@uoh.cl](mailto:hector.bahamonde@uoh.cl)

**w:** [www.hectorbahamonde.com](http://www.hectorbahamonde.com)

**Curso:** MLE.

**TA:** Gonzalo Barria.

## I. PROPIEDADES DE LOS ESTIMADORES MLE

1. Invariance to reparameterization: estimaciones se pueden transformar y no alteran su valor sustantivo. Por ej., tomar un log o elevar al cuadrado.
2. Invariance to sampling plans: debido a que los estimadores dependen de los datos usados (son particulares a ellos, y no son generales), Es por esto que variando el tamaño de la muestra no varía la calidad de los estimadores.
3.  $\hat{\theta}$  no está sesgado. Es decir, en la medida que se repitan los experimentos,  $\hat{\theta}$  no cambia.
4.  $\hat{\theta}$  es consistente. Dentro de todo el “parameter space”, existe un “spike” (una punta) que representa el verdadero parametro  $\hat{\theta}$ .
5. El “parameter space” de  $\hat{\theta}$  esta normalmente distribuido.

## II. PRECISIÓN DE LOS ESTIMADORES MLE

Pensar en la precisión, es pensar en cuán bien (o mal) nuestro estimador  $\hat{\theta}$  (i.e. “nuestro  $\beta$ ”) maximice el likelihood the que  $E(y) = \pi$ . Para esto, debemos recordar que la función del  $LL$  es relativa (depende de los datos). No es como antes en OLS, donde podíamos comparar  $p$ -values,  $r^2$  y otros *entre modelos con distintos datasets*. Aquí no.

### Likelihood Ratio Test (LLR)

$$\begin{aligned}\mathfrak{R} &= 2\ln\left(\frac{L_{R_*}}{L_*}\right) \\ &= 2(\ln L_* - L_{R_*})\end{aligned}\tag{1}$$

donde  $L_*$  es el likelihood del modelo “entero” y  $L_{R_*}$  es el likelihood del modelo “restringido”. “Entero” significa que tiene todos los efectos estimados, mientras que el “restringido” tiene los efectos *restringidos* a 0.

Volvamos a usar el lenguaje OLS para ver qué significa “entero” y “restringido”. Supongamos que tenemos dos modelos compitiendo; **ambos se construyeron usando la misma base de datos** (entonces, los podemos comparar).

$$y_i = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \epsilon_i \quad (2)$$

$$\begin{aligned} y_i &= \beta_0 + 0x_1 + \beta_2 x_2 + \epsilon_i \\ y_i &= \beta_0 + 0 + \beta_2 x_2 + \epsilon_i \end{aligned} \quad (3)$$

Aquí lo que hemos hecho es que el modelo en Equation 2 está “entero”. Sin embargo, el modelo en la Equation 3 está “restringido”; hemos “restringido” el valor de  $\beta_1 = 0$ . Nota que  $0 \times x_1 = 0$ . La entonces pregunta que nos ayuda a resolver el LLR es *qué modelo es mejor? El restringido o el entero?* Comparemos sus respectivos LLRs.

Si  $L_* = L_{R_*}$  entonces  $\mathfrak{R} = 1$ . Pero si el likelihood del modelo “entero”  $L_*$  es mejor, entonces  $\mathfrak{R} \geq 1$ . Por ejemplo, si  $L_* = -72.86$  y  $L_{R_*} = -81.27$ , entonces,

$$\begin{aligned} \mathfrak{R} &= 2\ln\left(\frac{L_{R_*}}{L_*}\right) \\ &= 2(\ln -72.86 - -81.27) \\ &= 16.8 \end{aligned} \quad (4)$$

Aquí podemos concluir que el modelo “entero” es mejor, y que debemos quedarnos con este.

**Wald Test** El LRT funciona cuando mejor cuando tenemos un número limitado de hipótesis. En el ejemplo anterior contrastamos la hipótesis donde Equation 2 era mejor que Equation 3 (y concluimos

que Equation 2 era mejor). *Qué pasa cuando tienes muchas hipótesis y resulta complicado restringir varios parametros a cero?* Para eso usamos el *Wald test*. La ventaja de este test es que “only the unrestricted model need be estimated; from that model, one can perform tests against any number of alternatives” (King 1998, p. 87).

El Wald test es un tipo de t-test. De nuestro conocimiento de OLS sabemos que una vez obtenido el t-test, es posible calcular el p-value.

Recordemos primero el t-test:

$$t = \frac{\hat{\mu}_s - \tilde{\mu}_p}{\frac{\hat{\sigma}}{\sqrt{n}}} \quad (5)$$

donde  $\hat{\mu}_s$  es el *sample mean* (lo que observamos),  $\tilde{\mu}_p$  es el *population mean* (lo que no observamos), y  $\hat{\sigma}$  es la desviación estándar estimada. Ahora veamos el Wald test,

$$\mathbb{W} = \frac{\hat{\beta} - \tilde{\beta}}{\hat{\sigma}} \quad (6)$$

donde, de manera análoga al t-test en Equation 5,  $\hat{\beta}$  es el valor promedio estimado (lo que observamos), y a diferencia del t-test,  $\tilde{\beta}$  es un posible valor de  $\beta$ , mientras que  $\hat{\sigma}$  es el error estándar de  $\hat{\beta}$ .

Veamos el siguiente ejemplo, donde de nuevo trataremos de testear la diferencia entre nuestro modelo “entero” (Equation 2) y nuestro modelo “restringido” (Equation 3). Supongamos que nuestro modelo OLS en la Equation 2  $\hat{\beta}_1 = -2.30$  (con error estándar estimado de  $\hat{\sigma} = 0.5$ ), y que nosotros queremos testear si  $\hat{\beta}_1 = 0$ , o más precisamente, que uno de los posibles valores de  $\hat{\beta}_1$  es  $\tilde{\beta}_1 = 0$ . Para eso, restringimos nuestro modelo (como en Equation 3).

$$\begin{aligned} \mathbb{W} &= \frac{\hat{\beta}_1 - \tilde{\beta}_1}{\hat{\sigma}} \\ \mathbb{W} &= \frac{-2.30 - 0}{0.5} \\ \mathbb{W} &= -4.60 \end{aligned} \quad (7)$$

Dado que  $\mathbb{W} = -4.60$ , podemos sugerir que el modelo restringido (Equation 3) esta  $-4.60$  **desviaciones estándar lejos** del modelo entero (Equation 2)—es decir, ambos son substancialmente diferentes. Si realmente  $\hat{\beta}_1 = 0$ , entonces  $\tilde{\beta}_1 = 0$ , lo que hubiera implicado que  $\mathbb{W} = 0$ , pero en este caso es  $-4.60$ . Esto significa que debemos rechazar la idea de que  $\hat{\beta}_1 = 0$  (rechazando así el modelo restringido, Equation 3), y quedándose con el modelo entero (Equation 2) donde  $\hat{\beta}_1 = -2.30$ .

- La ventaja del Wald test es que podemos testear si múltiples parámetros son iguales a cero (u otro valor).
- Debiera ser claro en este momento que ultimamente, lo que busca este test, es sugerir si un parámetro aporta al modelo (mejorando su likelihood) o no.

## REFERENCES

King, Gary (1998). *Unifying Political Methodology: The Likelihood Theory of Statistical Inference*. Ann Arbor, MI: University of Michigan Press, pp. 1–274.