

Profesor: Héctor Bahamonde, PhD.

e: hector.bahamonde@uoh.cl

w: www.hectorbahamonde.com

Curso: MLE.

TA: Gonzalo Barria.

I. OUTCOMES DE CUENTAS

En la primera mitad de la clase abordaremos el modelo Poisson. La idea es que cuando el supuesto clave de este modelo no se cumple, tenemos la alternativa del modelo Negative-Binomial que relaja ese supuesto

I. Modelo Poisson

Motivación Muchas veces estamos interesados en procesos de cuentas: en número de veces que visitas a un doctor, el número de asaltos que se produce en tu ciudad, arrestos, etc. Aunque muchos analistas insisten en que estos *data generating processes* pueden ser estimados vía modelos OLS, este tipo de prácticas seriamente sesga las estimaciones (Long 1997, p. 217). Es para esto que necesitamos métodos de MLE para estimarlos.

Este tipo de procesos los llamamos “de cuentas” porque se refieren a cuántas veces cierto proceso se repite. Si te fijas, cada realización del evento ocurre de manera discreta (es decir, *sin* números decimales) y de manera positiva. **Recuerda:** los métodos OLS suponen variables dependientes continuas—“con decimales” y donde $y_i = \{-\infty, \infty\}$. Esto *no* ocurre con los modelos Poisson.

Supuestos Distribucionales Los modelos Poisson son uno de los modelos MLE más básicos. Cada evento i está determinado por una distribución Poisson. Existe una característica muy importante en este tipo de distribuciones: la media (condicional) y la varianza (condicional) son iguales (Long 1997, p. 218).

En otras palabras,

$$E(y_i|\mathbf{x}_i) = \text{Var}(y_i|\mathbf{x}_i) = \mu \quad (1)$$

lo que llamamos **equidispersion**. Nota que μ es un escalar. Que la **media sea constante** es

una consecuencia directa de que asumamos independencia entre las probabilidades de los eventos y la cantidad (“cuenta”) de eventos: da lo mismo la cantidad de cuentas, todas siempre tendrán la misma probabilidad, y por tanto, la misma media μ . Esto es lo que mas abajo llamaremos **independencia estocástica**.

Este modelo se construye en base a supuestos que no siempre se cumplirán. En estos casos, existen otras distribuciones (y estimaciones) alternativas:

1. **Negative Binomial**: cuando la varianza no es igual que la media (**overdispersion**). (Esta clase).
2. **Zero-Inflate Poisson**: cuando la cantidad de ceros es excesiva. (Otra clase).

Continuando con la distribución Poisson, ésta se puede definir como,

$$Pr(y_i|\mu) = \frac{\exp(-\mu)\mu^{y_i}}{y_i!} \quad (2)$$

para cada $y_i = 0, 1, 2, \dots$. El parámetro μ se conoce como “rate” y representa el número esperado de veces de que un evento ocurre en un espacio de tiempo. Más específicamente,

$$\mu = E(y_i|\mathbf{x}_i) = \exp(\mathbf{x}_i\boldsymbol{\beta}) \quad (3)$$

Como lo indica la [Equation 3](#), el símbolo “|” denota condicionalidad. Y como en clases anteriores, $\mathbf{x}_i\boldsymbol{\beta}$ representa el modelo estructural.

Otro de los supuestos importantes, es que las realizaciones de los eventos son asumidas como independientes. Esta **independencia estocástica** implica que, por ejemplo, los procesos con realizaciones $y_i = 1$ son independientes de los procesos $y_i = 2$, y así sucesivamente. **Creemos en ese supuesto?** Piensa en la cantidad de *papers* que publica un profesor: la cantidad de *papers* que publicaste en el pasado no influye en la cantidad de *papers* que publicas en el presente. **Te suena bien?**

Estimación: Probabilidades y Likelihood Continuando con la [Equation 3](#), la probabilidad condicional de y_i está dada por,

$$Pr(y_i|\mathbf{x}_i) = \frac{\exp(-\mu)\mu^{y_i}}{y_i!} \quad (4)$$

Asumiendo independencia, tenemos que la función likelihood es la siguiente,

$$L(\boldsymbol{\beta}|\mathbf{y}, \mathbf{x}) = \prod_{i=1}^N \Pr(y_i|\mu) = \prod_{i=1}^N \frac{\exp(-\mu)\mu^{y_i}}{y_i!} \quad (5)$$

Tomando en cuenta la [Equation 4](#) y la [Equation 5](#), es fácil notar que $L(\boldsymbol{\beta}|\mathbf{y}, \mathbf{x})$ es simplemente la sumatoria de las probabilidades de cada evento y_i .

Sumando todas estas piezas de información en [Equation 1](#) y [Equation 3](#), tenemos que,

$$\mu = E(y_i|\mathbf{x}_i) = \text{Var}(y_i|\mathbf{x}_i) = \exp(\mathbf{x}_i\boldsymbol{\beta}) \quad (6)$$

Es por esto que decimos que este es uno de los modelos sencillos que tiene MLE para ofrecer.

II. PROGRAMACIÓN

Carguemos los datos:

```
p_load(foreign)
dat = read.dta("https://github.com/hbahamonde/MLE/raw/master/Datasets/banks.dta")
# cambiemos el nombre de la variable dependiente exec_chg
p_load(tidyverse)
dat = dat %>% rename(exec_chg = exec_chg, regime_type = regime_type)
```

Hagamos un resumen,

```
summary(dat)
```

##	ccode	year	guerilla	demonstrations
##	Min. : 10.0	Min. :1815	Min. : 0.000	Min. : 0.00
##	1st Qu.: 327.0	1st Qu.:1887	1st Qu.: 0.000	1st Qu.: 0.00
##	Median : 600.0	Median :1956	Median : 0.000	Median : 0.00
##	Mean : 649.9	Mean :1934	Mean : 0.207	Mean : 0.45
##	3rd Qu.: 990.0	3rd Qu.:1981	3rd Qu.: 0.000	3rd Qu.: 0.00
##	Max. :1300.0	Max. :1999	Max. :34.000	Max. :60.00
##			NA's :5021	NA's :5021

```

##          legislat_eff          coalitions
## None.  No legislature: 950  no coal. no opp      :3132
## Ineffective          :2674  >1 party, no opposit.: 172
## Part. Effect.        :1263  >1 party, opposit.  :1631
## Effective            :1837  >1 party, no coalit. :1783
## NA's                 :7002  NA's              :7008
##
##
##          party_legit    party_frac    regime.type
## No parties            :3036  Min.    : 0  Civilian          :11897
## Exclusion              : 896  1st Qu.: 0  Military-Ciilian: 1009
## 1or+ extremist part.: 686  Median :4153  Military          : 277
## No parties excluded :2100  Mean   :3486  Other              : 187
## NA's                  :7008  3rd Qu.:6429  NA's              : 356
##                      Max.    :9983
##                      NA's    :5122
##      coups      cabinet_size      exec.chg      num_elections
## Min.    :0.0000  Min.    : 0.0  Min.    :0.0000  Min.    :0.0000
## 1st Qu.:0.0000  1st Qu.: 8.0  1st Qu.:0.0000  1st Qu.:0.0000
## Median :0.0000  Median : 13.0  Median :0.0000  Median :0.0000
## Mean    :0.0408  Mean    : 14.6  Mean    :0.2286  Mean    :0.2301
## 3rd Qu.:0.0000  3rd Qu.: 19.0  3rd Qu.:0.0000  3rd Qu.:0.0000
## Max.    :3.0000  Max.    :109.0  Max.    :8.0000  Max.    :3.0000
## NA's    :357    NA's    :1427  NA's    :701    NA's    :2503
##      _est_poisson      _est_zinb
## Min.    :0.0000  Min.    :0.0000
## 1st Qu.:0.0000  1st Qu.:0.0000
## Median :0.0000  Median :0.0000
## Mean    :0.4497  Mean    :0.4497
## 3rd Qu.:1.0000  3rd Qu.:1.0000
## Max.    :1.0000  Max.    :1.0000

```

```
##
```

En esta aplicación pensaremos en la variable `exec.chg`: número de veces en que los poderes ejecutivos cambian.

```
table(dat$exec.chg)
```

```
##
```

```
##      0      1      2      3      4      5      6      7      8
## 10577 2063  294   61   18    7    1    2    2
```

El paquete de R que usaremos se llama `glm`.

Estimemos el modelo,

```
modelo.p = glm(exec.chg ~ demonstrations + guerilla + regime.type, family="poisson", data=dat)
```

Hagamos una tabla.

```
p_load(texreg)
```

```
texreg(modelo.p) # usa "screenreg" no "texreg".
```

Nota que tenemos varios países:

```
length(unique(dat$ccode)) # 230 países
```

```
[1] 230
```

Esto significa que nuestros errores estándar están malos (porque nuestras observaciones no son independientes). Los coeficientes están bien, pero los errores estándar están sesgados (y en consecuencia, nuestros intervalos de confianza, y en consecuencia, nuestra significancia estadística). Muchas veces los analistas dejan esto así (“pooled standard errors”), sin embargo esto ha sido altamente criticado (Green, Kim, and Yoon 2001). Deberemos calcular los errores estandares por “cluster” (o controlando por el hecho de que hay “grupos” de países en este análisis).

Este análisis toma bastante tiempo porque usa técnicas de re-samplio estadístico (*bootstrapping*).

	Model 1
(Intercept)	-1.59*** (0.03)
demonstrations	0.04*** (0.01)
guerilla	0.07*** (0.01)
regime.typeMilitary-Ciilian	0.09 (0.08)
regime.typeMilitary	0.71*** (0.10)
regime.typeOther	0.16 (0.23)
AIC	10073.24
BIC	10115.64
Log Likelihood	-5030.62
Deviance	6695.27
Num. obs.	8659

*** $p < 0.001$; ** $p < 0.01$; * $p < 0.05$

Table 1: *Statistical models*

```
p_load(clusterSEs)
cluster.bs.glm(modelo.p, dat = dat, ~ ccode, seed=2020, prog.bar = FALSE)

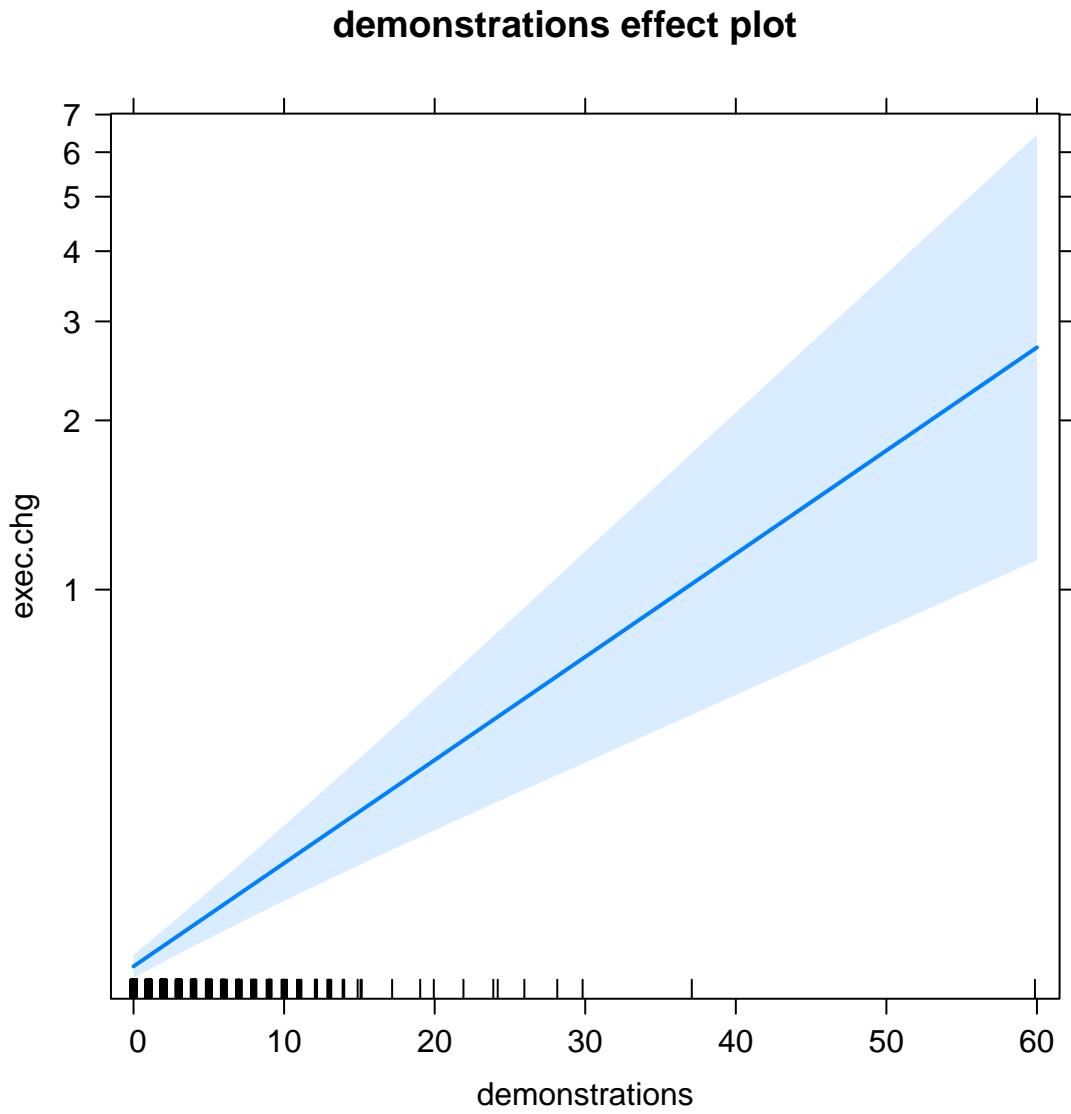
##
## Cluster Bootstrap p-values:
##
##          variable name      cluster bootstrap p-value
##          (Intercept)                0
##          demonstrations      0.05800000000000001
##          guerilla                0
## regime.typeMilitary-Ciilian      0.414
##          regime.typeMilitary      0
##          regime.typeOther      0.723
##
## Confidence Intervals (derived from bootstrapped t-statistics):
##
```

##	variable name	CI lower	CI higher
##	(Intercept)	-1.72621474132988	-1.45153089874607
##	demonstrations	-0.00189187479121188	0.0864002868580099
##	guerilla	0.0290397638432541	0.108481486804423
##	regime.typeMilitary-Ciilian	-0.137654889684297	0.324078888405253
##	regime.typeMilitary	0.45250859153439	0.976476573734113
##	regime.typeOther	-1.03658924142159	1.35016862595064


III. INTERPRETACIÓN

En cualquier caso, ya sabemos que la tabla poco valor tiene. Ahora procederemos a estimar los *predicted probabilities*.

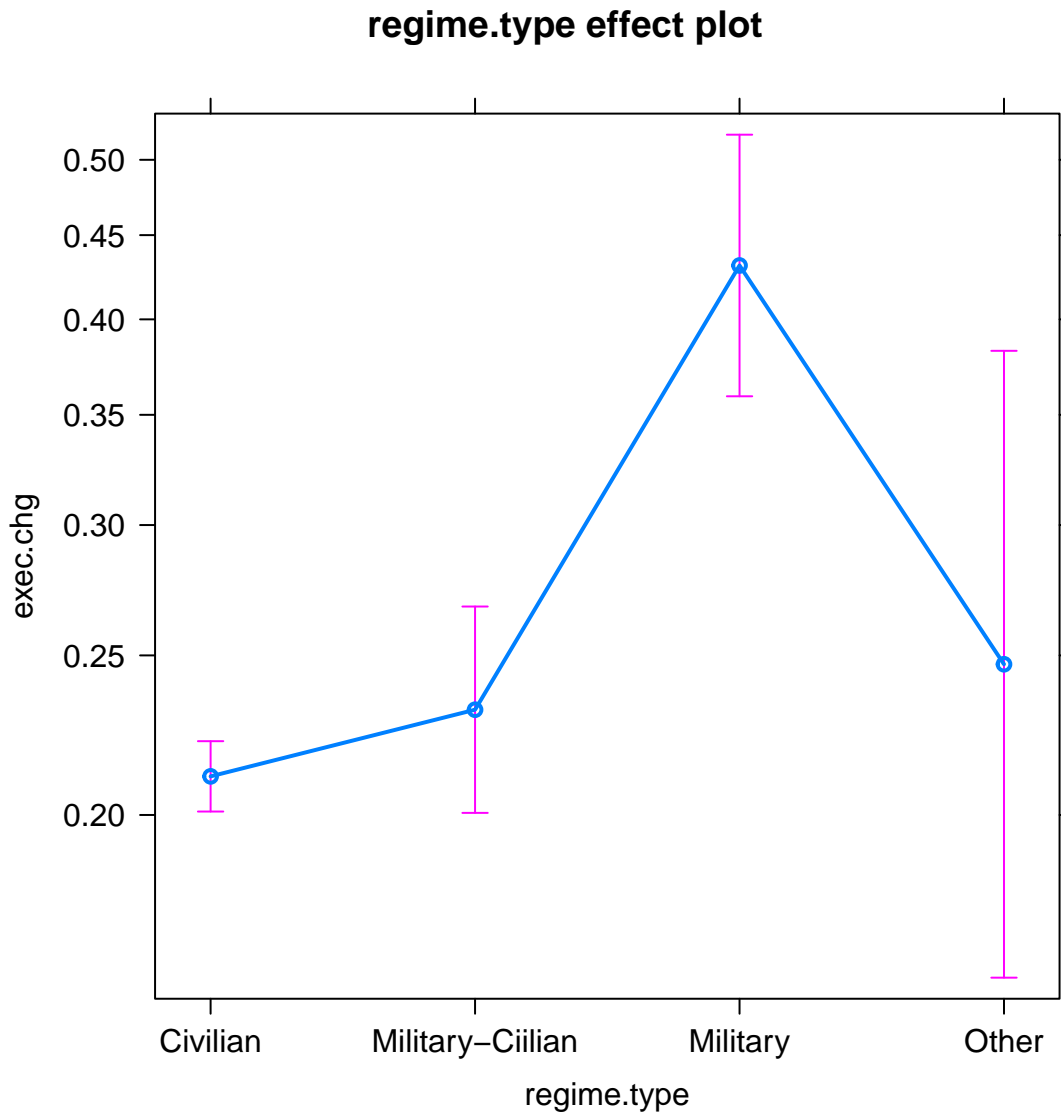
```
p_load(effects)
plot(effect("demonstrations", modelo.p))
```



```
plot(effect("guerilla", modelo.p))
```

```
plot(effect("regime.type", modelo.p))
```



Ahora, veamos si tenemos *overdispersion*. Para esto, usaremos el test desarrollado por Cameron and Trivedi (1990). Ellos explican que la hipótesis nula $E(y_i|\mathbf{x}_i) = \text{Var}(y_i|\mathbf{x}_i)$. Si el p-value es significativo, tendremos evidencia suficiente para sugerir que la media y la varianza no son iguales.

```
p_load(AER)
dispersiontest(modelo.p)
##
```

```
## Overdispersion test
##
## data:  modelo.p
## z = 5.6944, p-value = 0.000000006192
## alternative hypothesis: true dispersion is greater than 1
## sample estimates:
## dispersion
##      1.229601
```

El test es altamente significativo, por lo que sí tenemos evidencia a favor de overdispersion. Entonces deberemos pasar el modelo Negative-Binomial.

I. Modelo Negative-Binomial

Muy rara vez el modelo Poisson cumple su supuesto (Long 1997, p. 230). Lo que haremos será generalizar Equation 4, y permitir que exista heterogenidad no-observada vía la introducción de un residuo e_i (que hasta el momento el modelo Poisson no lo permitía).

En consecuencia, ahora tenemos que el “*rate*” del modelo Negative-Binomial está dado por,

$$\tilde{\mu}_i = \exp(\mathbf{x}_i\boldsymbol{\beta}) + \exp(\epsilon_i) \quad (7)$$

Nota que ahora μ_i es un vector (i.e. una distribución), no un escalar. Esto se traduce en el hecho de que tendremos distintos valores de μ_i según las distintas combinamos de valores en las variables independientes \mathbf{x}_i .

Supuestos Distribucionales El supuesto distribucional es que $\exp(\epsilon_i)$ (o muchas veces llamado el parámetro δ) toma el valor de $E(\exp(\epsilon_i)) = 1$.

- De manera muy importante, esta sigue siendo una distribución Poisson, pero “modificada” (de hecho el valor esperado sigue siendo el mismo, sólo cambia la varianza).
- Nota además que δ (como cualquier varianza) es *desconocida* (es un “*population parameter*”).
- Finalmente, parte del supuesto es que δ se distribuye siguiendo la distribución Gamma.

	Model 1	Model 2
(Intercept)	−1.59*** (0.03)	−1.60*** (0.03)
demonstrations	0.04*** (0.01)	0.05*** (0.01)
guerilla	0.07*** (0.01)	0.09*** (0.02)
regime.typeMilitary-Ciilian	0.09 (0.08)	0.09 (0.08)
regime.typeMilitary	0.71*** (0.10)	0.71*** (0.11)
regime.typeOther	0.16 (0.23)	0.15 (0.25)
AIC	10073.24	9954.78
BIC	10115.64	10004.25
Log Likelihood	−5030.62	−4970.39
Deviance	6695.27	5398.93
Num. obs.	8659	8659

*** $p < 0.001$; ** $p < 0.01$; * $p < 0.05$

Table 2: *Statistical models*

Contagio La flexibilidad del modelo Negative-Binomial permite modelar situaciones de **contagio**. Esto se refiere a situaciones donde la probabilidad de obtener ciertas cuentas está correlacionada con el número de cuentas. Volviendo al ejemplo de *papers* publicados, en la especificación Negative-Binomial podríamos modelar la situación donde los académicos tienen más probabilidades de publicar *papers* mientras más *papers* tengan publicados! Esto se refiere a que el modelo permite tomar en cuenta *data generating processes* que **no asuman independencia estocástica**.

Estimación Ahora procedamos a estimar el modelo.

```
p_load(MASS)
modelo.nb = glm.nb(exec.chg ~ demonstrations + guerilla + regime.type, data=dat)
```


Y de hecho comparemos ambos modelos,

```
p_load(texreg)
texreg(list(modelo.p, modelo.nb)) # usa "screenreg" no "texreg".
```

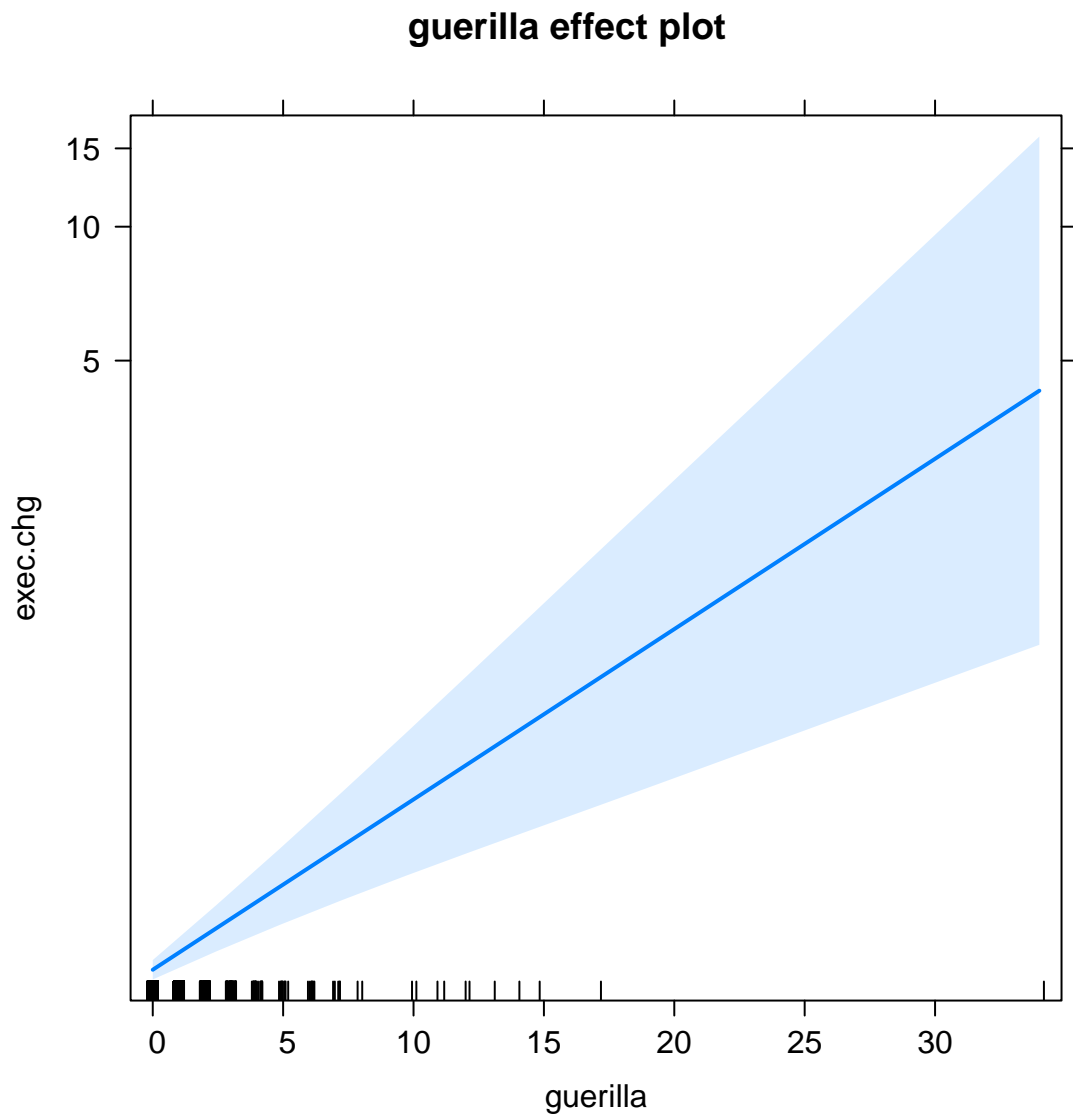
Encontramos—sin sorpresa—que los modelos son altamente parecidos.

Interpretación En cualquier caso, ya sabemos que la tabla poco valor tiene. Ahora procederemos a estimar los *predicted probabilities*.

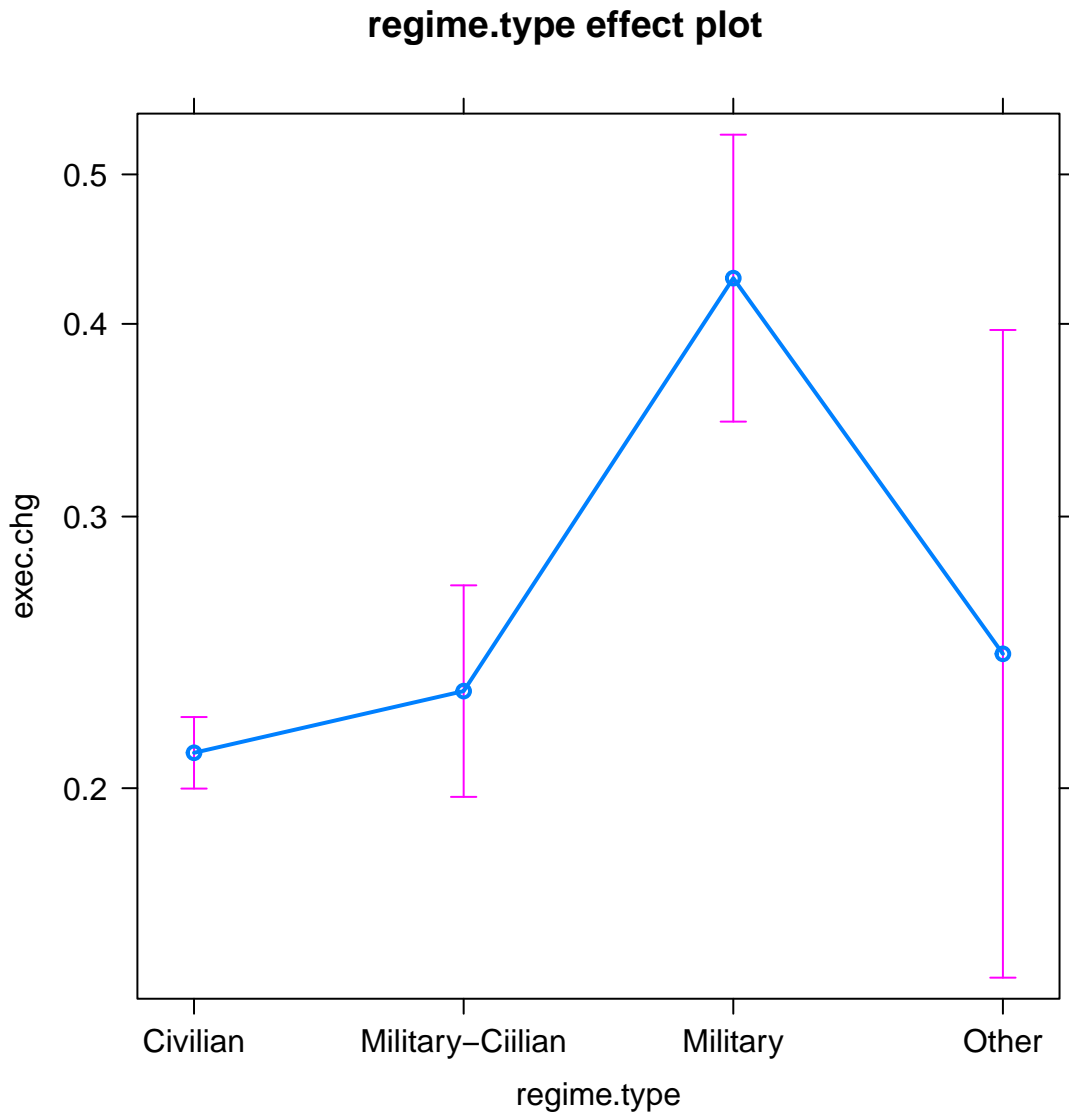
```
p_load(effects)
plot(effect("demonstrations", modelo.nb))
```



```
plot(effect("guerilla", modelo.nb))
```



```
plot(effect("regime.type", modelo.nb))
```



```
knitr::purl('Multinomial.Rnw')  
  
## Error in file(con, "r"): no se puede abrir la conexi'on  
  
Stangle('Multinomial.Rnw')  
  
## Error in SweaveReadFile(file, syntax, encoding = encoding): no Sweave file with  
name 'Multinomial.Rnw' found
```